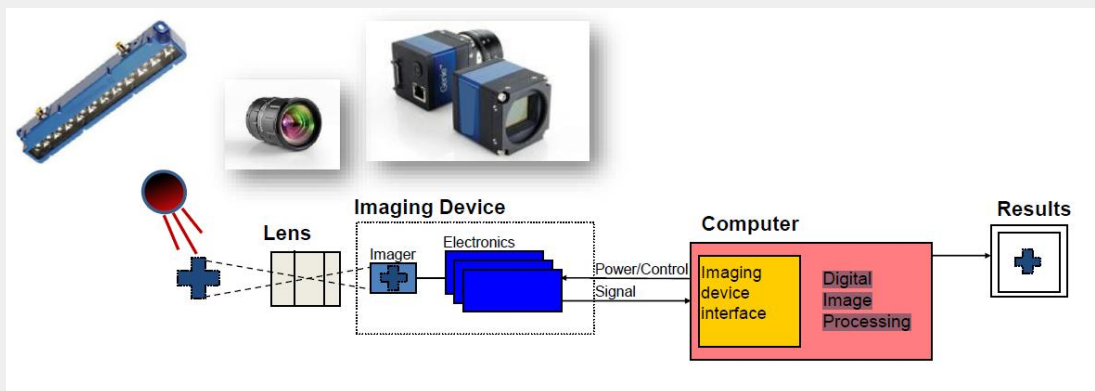


PRESENTACION DE PROYECTO INTEGRADOR

VISION ARTIFICIAL DE APILAMIENTO DE PANALES

Proyecto desarrolla un **prototipo de sistema de visión artificial basado en machine learning supervisado** para la **inspección de apilamiento de pañales** previo al empaque. La solución integra una arquitectura típica de visión por computadora compuesta por **cámara industrial, lentes de precisión, procesamiento digital en computador y software de IA.**



Profesor	Prof. Gladys Villegas, PhD.
Materia	PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL – MIAR0545
Alumnos	Francisco Javier Estupiñán Andrade David Alejandro Narváez Mejía
Fecha	09/19/2025

TABLA DE CONTENIDO

1.	MAPA DEL ESTADO DEL ARTE.....	4
1.1	TABLA DE MAPA QUÉ SE SABE Y CÓMO LO APLICAMOS.....	4
1.2	TIMELINE DE AVANCES EN VISIÓN POR COMPUTADORA 2020–2025.....	5
1.3	VACÍOS Y OPORTUNIDAD.....	7
1.4	LÍNEA BASE RECOMENDADA.....	7
1.5	ANÁLISIS FODA.....	7
1.6	REFERENCIAS.....	8
2.	ANÁLISIS DE DATASETS DISPONIBLES.....	10
2.1	CALIDAD DE LOS DATOS.....	10
2.2	TAMAÑO DEL DATASET.....	10
2.3	ACCESIBILIDAD.....	10
2.4	SESGOS POTENCIALES.....	10
2.5	PROCESAMIENTO DE DATOS.....	11
2.6	FUENTES PRINCIPALES DE DATASETS ABIERTOS PARA INVESTIGACIÓN.....	11
2.7	DESCRIPCIÓN DEL DATASET 1 – PILAS DE PAÑALES.....	11
2.8	DESCRIPCIÓN DEL DATASET 2 – JARRAS.....	12
2.9	DESCRIPCIÓN DEL DATASET 3 – BARRILES.....	12
2.10	TABLA COMPARATIVA DE DATASET.....	13
2.11	CODIGO FUENTE EJEMPLO.....	13
3.	DEFINICIÓN DE MÉTRICAS DE ÉXITO.....	14
3.1	MÉTRICAS TÉCNICAS.....	14
3.2	MÉTRICAS DE IMPACTO.....	14
3.3	UMBRALES DE ÉXITO.....	15
4.	ANÁLISIS DE STAKEHOLDERS.....	17
4.1	PRIMARIOS.....	17
4.2	SECUNDARIOS.....	17
4.3	SPONSORS.....	17
5.	DOCUMENTOS DE ALCANCE DEL PROYECTO.....	18
5.1	OBJETIVO GENERAL:.....	18

5.2	OBJETIVOS ESPECÍFICOS:.....	18
5.3	ALCANCE INCLUIDO:	18
5.4	ALCANCE EXCLUIDO:	19
5.5	CRITERIOS DE ACEPTACIÓN:	19
6.	CRONOGRAMA CON METODOLOGÍA ÁGIL.....	20
6.1	ROLES SCRUM DEL PROYECTO.....	20
6.2	DIAGRAMA GANTT	21
6.3	SPRINT 1 – INVESTIGACIÓN Y DISEÑO.....	21
6.4	SPRINT 2 – DESARROLLO CORE.....	21
6.5	SPRINT 3 – OPTIMIZACIÓN Y VALIDACIÓN	22
6.6	SPRINT 4 – FINALIZACIÓN Y DOCUMENTACIÓN	22
7.	PLAN DE RECURSOS	23
7.1	RECURSOS HUMANOS.....	23
7.2	RECURSOS TÉCNICOS.....	23
7.3	RECURSOS FINANCIEROS	24
8.	HITOS Y ENTREGABLES	25

1. MAPA DEL ESTADO DEL ARTE

El problema central radica en la verificación visual del apilamiento previo al empaque, actividad que expone a los operarios a riesgos ergonómicos y asépticos, al tiempo que demanda eficiencia en tiempo real.

La tendencia dominante evidencia que las soluciones basadas en Deep Learning, particularmente las CNN con técnicas de transfer learning y modelos de detección como YOLO o EfficientDet, superan ampliamente a la visión clásica en robustez y velocidad, lo que las convierte en la alternativa más competitiva para líneas industriales.

No obstante, persisten cuellos de botella asociados a la escasez de datos, la sensibilidad a cambios de dominio (iluminación y posición) y la latencia de procesamiento. Frente a ello, la literatura propone buenas prácticas como el aumento de datos, la anotación eficiente mediante *active learning*, la validación con métricas estandarizadas (mAP, IoU, F1-score) y el despliegue en edge computing cuando el tiempo de respuesta es crítico.

Finalmente, se identifican vacíos de investigación y aplicación en el control de calidad de productos higiénicos como los pañales, donde la ausencia de conjuntos de datos públicos y la necesidad de protocolos de validación en entornos controlados —especialmente con datasets reducidos, como el de 100 imágenes de este proyecto— abren una oportunidad estratégica para la innovación académica e industrial.

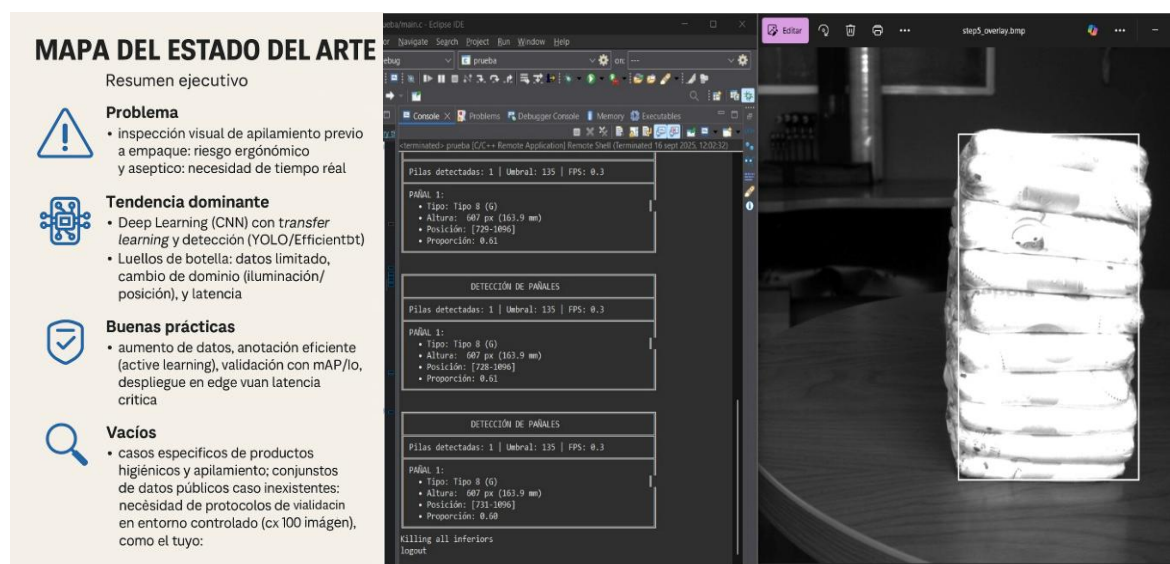


Figura 1: Visión Artificial Apilamiento / FUENTE: EVA ENGINEERING

1.1 TABLA DE MAPA QUÉ SE SABE Y CÓMO LO APLICAMOS

Panorama y tendencias:

- ✓ Dominio: inspección visual industrial con Deep Learning (DL) supera visión clásica en robustez y precisión [6],[22].
- ✓ Arquitecturas: clasificación y detección en tiempo real (YOLO/Faster R-CNN) [3],[4],[10]; detección de anomalías tipo PaDiM [4].
- ✓ Pequeños datasets: transfer learning + data augmentation + regularización [21],[22].
- ✓ Despliegue: exigencias de FPS/latencia [10]; métricas estándar mAP, IoU, F1 [4],[6].
- ✓ Ingeniería de visión: calibración, iluminación y geometría siguen siendo críticos [25].
- ✓ Ética/impacto: transparencia de métricas y rol humano [27].

Taxonomía por líneas → decisiones de proyecto:

- ✓ Clasificación vs Detección: PoC con clasificación binaria [3],[10].
- ✓ Anomalías (defectos raros): uso de PaDiM si se define apilado incorrecto como anomalía [4].
- ✓ Datos limitados: transfer learning y augmentation [21],[22].
- ✓ Síntesis de datos: generación ligera para variabilidad [3].

Línea / Tema	Hallazgos clave (qué se sabe)	Limitaciones reportadas	Aplicabilidad a nuestro caso (PoC 100 imágenes)	Decisión de proyecto (cómo lo aplicamos)
Visión clásica vs Deep Learning	CNN superan a SIFT/HOG+SVM en robustez ante iluminación/rotación	Requiere datos etiquetados y tuning	Variabilidad de iluminación/posición en línea	Usar CNN en lugar de visión clásica
Clasificación vs Detección	Detección (YOLO/Faster R-CNN) localiza y clasifica en 1 paso	Anotación más costosa; complejidad	Para contar/validar posición de stacks	Fase 1: Clasificación binaria; Fase 2: Detección si añadimos cajas
Detección de anomalías (PaDiM)	Eficaz con defectos raros y pocos datos	Requiere definir bien "normal/anómalo"	"Apilado incorrecto" como anomalía	Explorar PaDiM si la anotación de cajas no es viable
Transfer learning	Mejora con pocos datos, converge rápido	Riesgo de desajuste de dominio	Dataset pequeño y variabilidad limitada	Transfer learning con congelación progresiva
Data augmentation	Aumenta robustez (rotación, brillo, blur, shift)	No reemplaza diversidad real	Compensa 100 imágenes	Augmentations agresivos y realistas
Regularización y overfitting	Dropout, batch-norm, early stopping	Puede degradar si se abusa	Modelo pequeño + pocos datos	Aplicar dropout + early stopping
Métricas estándar	mAP, IoU, F1-score para CV industrial	mAP sensible a distribución	KPI claros y trazables	Reportar F1, y si hay cajas: mAP@0.5, IoU
Tiempo real (FPS/latencia)	Modelos ligeros logran >30 FPS	Trade-off precisión ↔ velocidad	Línea requiere baja latencia	Medir FPS y latencia ≤2 s en piloto controlado
Ingeniería de cámara	Calibración, posición e iluminación son críticas	Si falla, baja el rendimiento del modelo	Montaje estable, iluminación constante	Checklist de instalación y calibración
Segmentación / preprocesado	Mejora señal y estabilidad del pipeline	Coste de cómputo y complejidad	Bordes/contornos de paquetes	Usar normalización + filtrado; segmentación opcional
Datos sintéticos / Sim2Real	Útil para clases raras	Requiere buen realismo	Pocas imágenes y variabilidad	Generación sintética ligera (fondos/iluminación)
MLOps ligero / reproducibilidad	Versionado de datos/modelos y semillas fijas	Curva de adopción	Proyecto corto (6 semanas)	Repositorio con semillas fijas y README de pipeline
Ética y seguridad	Transparencia de métricas, rol humano	Riesgo de opacidad	Operación con productos higiénicos	Reporte claro de métricas y límites del PoC
Validación en entorno controlado	Reduce ruido y sesgos externos	No refleja planta real	PoC con 100 imágenes	Protocolo reproducible de validación y reporte

Tabla 1: Mapa Estado del Arte Proyecto Integrado Visión Artificial / FUENTE: Generado ChatGPT

1.2 TIMELINE DE AVANCES EN VISIÓN POR COMPUTADORA 2020–2025

- ✓ Consolidación de YOLOv4 (Bochkovskiy et al.): mejoras en precisión y velocidad para tareas de detección en tiempo real.
- ✓ PaDiM (Patch Distribution Modeling) propuesto para detección de anomalías industriales sin gran cantidad de datos [4].
- ✓ Aumento del uso de transfer learning y data augmentation como solución a datasets pequeños en aplicaciones industriales.

2021

- ✓ YOLOv5 se convierte en estándar de facto en la comunidad open-source por su balance de rapidez y facilidad de uso.
- ✓ Publicación de frameworks con Faster R-CNN + generación sintética de defectos (GP-WGAN) para abordar defectos raros en entornos industriales [3].
- ✓ Métricas robustas como mAP@0.5 y F1-score se establecen como referencia obligatoria en inspección visual.

2022

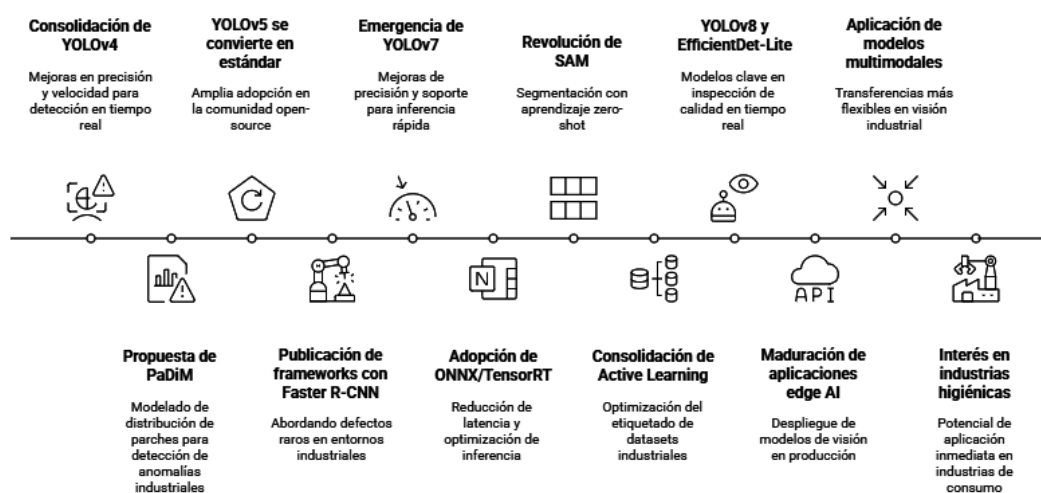
- ✓ Emergencia de YOLOv7 con mejoras de precisión y soporte para inferencia rápida en GPU/Edge.

- ✓ O'Reilly – Géron (3ra ed.) refuerza la importancia de pipelines ML completos (recolección → preprocesamiento → entrenamiento → validación → despliegue).
- ✓ Adopción de ONNX/TensorRT en despliegues industriales para reducir latencia y optimizar inferencia en hardware limitado.

2023

- ✓ Segment Anything Model (SAM, Meta AI) revoluciona segmentación con zero-shot learning, aplicable a inspección flexible sin datasets específicos.
- ✓ Consolidación de Active Learning en pipelines de visión para optimizar etiquetado de datasets industriales.
- ✓ Expansión de soluciones explainable AI (Grad-CAM, LIME) para visión, aplicadas en sectores con auditoría (farmacéutico, alimenticio).

Avances en Visión por Computadora



Made with Napkin

Figura 2: Línea de tiempo de avance de VA / FUENTE: Generado en Napkin

2024

- ✓ YOLOv8 y EfficientDet-Lite se posicionan como modelos clave en inspección de calidad en tiempo real.
- ✓ Libro Foundations of Computer Vision (MIT Press, 2024) aporta marcos actualizados para combinar visión clásica + DL en entornos industriales.
- ✓ Aplicaciones edge AI más maduras: NVIDIA Jetson y Coral TPU permiten desplegar modelos de visión en producción con baja latencia.
- ✓ Crece la aplicación en logística y empaques inteligentes (inspección automática de packaging) [8],[9].

2025 (estado actual)

- ✓ Modelos multimodales (ej. CLIP, Segment Anything v2) aplicados a visión industrial: permiten transferencias más flexibles.
- ✓ Scientific Reports (2025) publica casos de inspección industrial automatizada con visión avanzada y validación en producción [9].
- ✓ Mayor interés en industrias higiénicas y de consumo masivo: aún con vacíos de datasets, pero con potencial de aplicación inmediata (caso pañales → tu proyecto).
- ✓ Tendencia hacia protocolos estandarizados de validación (mAP, IoU, F1, FPS) en PoC con datasets pequeños.

1.3 VACÍOS Y OPORTUNIDAD

- ✓ Caso específico: apilamiento de pañales no estudiado.
- ✓ Datos escasos: oportunidad de validar técnicas de TL y augmentation [21],[22].
- ✓ Validación en controlado: necesidad de protocolo reproducible con métricas claras [4],[6],[10].

1.4 LÍNEA BASE RECOMENDADA

- ✓ Modelado: Clasificación binaria con transfer learning (MobileNet/EfficientNet-B0) [21],[22].
- ✓ Datos: augmentation dirigido (rotaciones, brillo, blur, shifts) [21].
- ✓ Métricas: F1, precisión, recall; mAP/loU si se usan bounding boxes [4],[6].
- ✓ Tiempo: medir FPS/latencia; exportar a ONNX si hace falta optimización [10].
- ✓ Ingeniería: checklist de cámara/iluminación [25].
- ✓ Ética/QA: reporte transparente de métricas y límites del PoC [27].

1.5 ANÁLISIS FODA

Fortalezas

- ✓ Base tecnológica sólida: Deep Learning (CNN, YOLO, EfficientDet) probado en múltiples industrias [1],[3],[10].
- ✓ Mejores métricas de desempeño: validación estandarizada con mAP, loU, F1 garantiza calidad y transparencia.
- ✓ Pipeline bien definido: prácticas consolidadas como data augmentation, transfer learning y regularización permiten resultados competitivos aun con datasets pequeños [21],[22].
- ✓ Enfoque académico-comercial dual: combina rigor científico con aplicabilidad práctica en líneas de producción.

Debilidades

- ✓ Dataset limitado (100 imágenes) que restringe la capacidad de generalización del modelo.
- ✓ Dependencia del preprocesamiento y calibración de cámara: cualquier error en iluminación/posición afecta fuertemente los resultados [25].
- ✓ Escasa literatura en el dominio específico (apilamiento de pañales), lo que obliga a extrapolar estudios de otros sectores.
- ✓ No se valida aún en planta real: el PoC se limita a entorno controlado, sin medir impacto operativo.

Oportunidades

- ✓ Innovación pionera en sector higiénico: casi no existen estudios ni aplicaciones en inspección de apilamiento de pañales.
- ✓ Escalabilidad hacia producción real: posibilidad de integrar con PLC/SCADA y medir reducción de intervención humana.
- ✓ Adopción de active learning para mejorar eficiencia en anotación de datos futuros.
- ✓ Edge computing: oportunidad de ofrecer soluciones comerciales optimizadas para baja latencia en líneas de empaque.
- ✓ Valor comercial agregado: diferenciación en el mercado al ofrecer control de calidad automatizado en productos de consumo masivo.

Amenazas

- ✓ Competencia tecnológica: soluciones comerciales de inspección automática ya existen en sectores alimenticios y farmacéuticos; riesgo de adopción lenta en higiénicos.
- ✓ Riesgo de obsolescencia rápida: modelos y frameworks de IA evolucionan constantemente, exigiendo actualizaciones permanentes.
- ✓ Barreras de implementación industrial: resistencia de operarios y necesidad de cumplir normas de inocuidad y auditorías.
- ✓ Limitaciones regulatorias y éticas: la automatización puede generar cuestionamientos sobre desplazamiento laboral y manejo de datos sensibles.

Con este FODA, queda claro que el Mapa del Estado del Arte no solo describe tendencias técnicas, sino que también guía una estrategia de escalamiento:

- ✓ Aprovechar fortalezas (CNN, métricas claras).
- ✓ Mitigar debilidades (dataset pequeño, entorno controlado).
- ✓ Capitalizar oportunidades (sector higiénico, edge computing).
- ✓ Enfrentar amenazas (competencia, regulación).

1.6 REFERENCIAS

- [1] N. Hütten, A. et al., "Deep Learning for Automated Visual Inspection in Industrial Applications," *Machines*, vol. 12, no. 1, p. 11, Jan. 2024.
- [2] S. Arian, K. Varanasi, and D. Stricker, "Surface Defect Classification in Real-Time Using Convolutional Neural Networks," *arXiv preprint*, arXiv:1904.04671, 2019.
- [3] M. Jalayer, R. Jalayer, A. Kaboli, C. Orsenigo, and C. Vercellis, "Automatic Visual Inspection of Rare Defects: A Framework based on GP-WGAN and Enhanced Faster R-CNN," *arXiv preprint*, arXiv:2105.00447, 2021.
- [4] T. Defard, A. Setkov, A. Loesch, and R. Audigier, "PaDiM: a Patch Distribution Modeling Framework for Anomaly Detection and Localization," *arXiv preprint*, arXiv:2011.08785, 2020.
- [5] T. Schlosser, F. Beuth, M. Friedrich, and D. Kowanko, "A Novel Visual Fault Detection and Classification System for Semiconductor Manufacturing Using Stacked Hybrid Convolutional Neural Networks," *arXiv preprint*, arXiv:1911.11250, 2019.
- [6] J. Villalba-Diez et al., "Deep Learning for Industrial Computer Vision Quality," *Sensors*, vol. 19, no. 22, pp. 4780, Nov. 2019.
- [7] A. Wan et al., "Deep learning-based intelligent visual inspection for defect detection in smoke sensor manufacturing," *Engineering Applications of Artificial Intelligence*, vol. 142, p. 107004, Jan. 2025.
- [8] J. Huang, "Automated Logistics Packaging Inspection Based on Deep Learning and Computer Vision: A Two-Dimensional Flow Model Approach," *Traitement du Signal*, vol. 42, no. 2, pp. 275–282, 2025.
- [9] "Advancing industrial inspection with an automated visual inspection tool powered by computer vision," *Scientific Reports*, vol. 15, art. no. 88974, Feb. 2025.
- [10] C. D. Hollander, S. Das, and S. Suliman, "Automating Visual Inspection with Convolutional Neural Networks," in *Proc. PHM Society Conf.*, 2019, pp. 868–875.
- [11] S. Yadav and R. Kennedy, "Vision Inspection Using Machine Learning/Artificial Intelligence," *Pharmaceutical Engineering*, Nov. 2020.
- [12] R. A. León, et al., "Design of an artificial vision algorithm to detect cracks in construction," in *Proc. LACCEI Int. Conf.*, Buenos Aires, 2023, pp. 1–9.
- [13] O. Barahona, "Design and Implementation of an Artificial Vision System for Defect Detection," *KnE Engineering*, 2022.
- [14] M. C. Nava, "CNN computer for high-speed visual inspection," in *Proc. SPIE 4301, VLSI Circuits and Systems*, 2001.
- [15] M. E. A. Macías et al., "Design and simulation of an artificial vision sorting machine and cocoa pulping machine," *Ciencia Latina*, vol. 6, no. 3, pp. 1456–1468, 2022.
- [16] T. Defard et al., "Anomaly detection in industrial applications with deep learning," *arXiv preprint*, arXiv:2011.08785, 2020.
- [17] M. Jalayer et al., "Faster R-CNN with synthetic data generation for rare defect inspection," *arXiv preprint*, arXiv:2105.00447, 2021.
- [18] J. Huang, "Deep learning for logistics packaging inspection," *Traitement du Signal*, vol. 42, no. 2, pp. 275–282, 2025.
- [19] J. Villalba-Diez et al., "Deep Learning for Industrial Quality Control," *Sensors*, vol. 19, no. 22, pp. 4780, 2019.

- [20] A. Wan et al., "Visual inspection with DL in sensor manufacturing," Eng. Appl. Artif. Intell., vol. 142, p. 107004, 2025.
- [21] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems, 3rd ed. O'Reilly Media, 2022.
- [22] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA: MIT Press, 2016.
- [23] J. C. Cuevas-Tello, "Apuntes de Redes Neuronales Artificiales," arXiv preprint, arXiv:1806.05298, 2018.
- [24] S. Soatto, Foundations of Computer Vision (Adaptive Computation and Machine Learning series). Cambridge, MA: MIT Press, 2024.
- [25] D. Forsyth and J. Ponce, Computer Vision: A Modern Approach, 2nd ed. Pearson, 2011.
- [26] Y. Goldberg, Neural Network Methods for Natural Language Processing. Morgan & Claypool, 2017.
- [27] F. Pasquale, Las nuevas leyes de la robótica. Madrid: Ediciones Paidós, 2024.

2. ANÁLISIS DE DATASETS DISPONIBLES

Dataset para aprendizaje automático supervisado en visión artificial es un conjunto estructurado de imágenes que han sido previamente **etiquetadas** con información que representa la verdad real (*ground truth*), como clases (ej. apilado correcto/incorrecto), regiones de interés (bounding boxes) o segmentos de objetos.

Este dataset constituye la base para entrenar modelos de machine learning, ya que permite que el algoritmo aprenda a identificar patrones visuales a partir de ejemplos conocidos y pueda generalizar en nuevas imágenes no vistas.

En aplicaciones industriales, como la inspección de apilamiento de pañales, el dataset debe reflejar condiciones reales de operación —variaciones de iluminación, ángulos y posibles errores de apilamiento— para garantizar que el modelo no solo logre precisión en laboratorio, sino también robustez y confiabilidad en escenarios de producción.

La esencia del prototipo radica en su capacidad de **identificar y estimar medidas de largo y ancho de objetos en imágenes** mediante técnicas de visión artificial. Este enfoque permite aplicar el modelo en diversos contextos visuales, tales como la detección de **carros, barcos o pilas de pañales**, donde la extracción de dimensiones resulta fundamental para tareas de inspección, clasificación o control de calidad.

Al integrar algoritmos de *machine learning supervisado* y redes convolucionales (CNN), el sistema no solo reconocerá la presencia de los objetos, sino que también podrá calcular sus proporciones con un nivel de precisión adecuado para pruebas en entorno controlado, sentando las bases para un futuro escalamiento hacia aplicaciones industriales más complejas.

2.1 CALIDAD DE LOS DATOS

- ✓ Imágenes nítidas, sin ruido excesivo ni distorsiones.
- ✓ Consistencia en condiciones de captura: iluminación, ángulos, resolución.
- ✓ Etiquetado correcto y revisado (ground truth confiable).
- ✓ Variedad suficiente de ejemplos de la clase positiva y negativa (apilado correcto/incorrecto).

2.2 TAMAÑO DEL DATASET

- ✓ **Prototipos académicos:** mínimo 100–500 imágenes (con data augmentation).
- ✓ **Modelos robustos:** >5,000 imágenes por clase.
- ✓ **Producción industrial:** decenas de miles para garantizar generalización.
- ✓ Regla práctica: mientras más clases (variaciones), mayor debe ser el dataset.

2.3 ACCESIBILIDAD

- ✓ Datos almacenados en formato estandarizado (JPEG/PNG + anotaciones en JSON/CSV).
- ✓ Versionamiento (ej. Git, DVC, Kaggle datasets).
- ✓ Acceso compartido entre equipo (Google Drive, GitHub, plataformas cloud).
- ✓ Cumplimiento con regulaciones de privacidad/inocuidad en caso de productos sensibles.

2.4 SESGOS POTENCIALES

- ✓ **Iluminación:** dataset capturado solo en condiciones ideales → falla en escenarios reales.
- ✓ **Posición/ángulo:** imágenes tomadas desde un único ángulo → baja generalización.
- ✓ **Clase desequilibrada:** exceso de ejemplos correctos y muy pocos incorrectos → modelo sesgado.
- ✓ **Contexto:** fondos uniformes que no reflejan ruido real de la planta.
- ✓ **Mitigación:** balance de clases, aumento de datos, muestreo estratificado y validación cruzada.

2.5 PROCESAMIENTO DE DATOS

- ✓ Preprocesamiento: normalización de píxeles, reducción de ruido, resizing.
- ✓ Data augmentation: rotación, cambio de brillo, desenfoque, zoom, traslación.
- ✓ Anotación: bounding boxes, segmentación o etiquetas binarias según objetivo.
- ✓ Split: separación clara en entrenamiento (70%), validación (20%) y prueba (10%).

2.6 FUENTES PRINCIPALES DE DATASETS ABIERTOS PARA INVESTIGACIÓN

- ✓ ImageNet → dataset de referencia con millones de imágenes etiquetadas.
- ✓ COCO (Common Objects in Context) → 330k imágenes con anotaciones detalladas, usado para métricas mAP/IoU.
- ✓ Open Images Dataset (Google) → 9M imágenes con anotaciones para visión general.
- ✓ Kaggle Datasets → amplia variedad de conjuntos (defectos industriales, empaques, etc.).
- ✓ VisualData.io → repositorio de datasets de visión por computadora categorizados.
- ✓ MVTec AD → datasets de inspección industrial (anomalías, defectos de calidad).
- ✓ Roboflow Universe → repositorio colaborativo con datasets etiquetados para proyectos de IA.

2.7 DESCRIPCIÓN DEL DATASET 1 – PILAS DE PAÑALES

Descripción técnica: El dataset está compuesto por 100 imágenes digitales que registran pilas de pañales en diferentes posiciones y condiciones de apilamiento. Cada imagen tiene un formato JPG con resolución estándar adecuada para entrenamiento de modelos de visión artificial ($\approx 640 \times 640$ px). La estructura de datos sigue un esquema de clasificación binaria (correcto/incorrecto), lo que permite su uso en tareas de inspección visual automatizada.

Procedencia de los datos: Las imágenes fueron generadas en un entorno controlado por la empresa EVA ENGINEERING, como parte de su apoyo al presente proyecto. El dataset se encuentra registrado bajo el código IN34-EVA1200 REV 01, lo que garantiza trazabilidad y control documental interno.

Licencia y condiciones de uso: La licencia de uso ha sido otorgada por EVA ENGINEERING de manera exclusiva para fines de investigación académica en el marco del prototipo de visión artificial desarrollado durante la maestría. Queda restringido su uso para fines comerciales o distribución externa sin autorización expresa de la empresa.

Calidad del dataset: Las imágenes mantienen consistencia en iluminación, ángulo y distancia de captura, lo que asegura uniformidad en el entrenamiento del modelo. Adicionalmente, el dataset fue revisado para garantizar que las etiquetas asignadas reflejen fielmente el estado de apilamiento, logrando un nivel de calidad confiable para experimentación en entornos controlados.

Rol dentro del proyecto: Este constituye el dataset principal, sobre el cual se realizará el entrenamiento inicial del modelo supervisado de visión artificial (CNN), incluyendo etapas de preprocesamiento, normalización y *data augmentation* para mejorar la robustez ante variaciones futuras.



Figura 3: Pila de Pañales / FUENTE: EVA ENGINEERING S.A.

2.8 DESCRIPCIÓN DEL DATASET 2 – JARRAS

Descripción técnica: El dataset contiene imágenes de jarras pertenecientes a la colección Caltech-101, con un tamaño promedio de 300×300 píxeles y en formato JPG. La estructura está organizada en carpetas por clase, lo que facilita la clasificación supervisada. En este proyecto, se emplea un subconjunto de imágenes de jarras para entrenar y validar la capacidad del modelo en estimación de dimensiones (alto y ancho) y clasificación de objetos con formas regulares.

Procedencia de los datos: Los datos provienen del repositorio público de Kaggle: Caltech-101 Dataset, un conjunto reconocido en investigación académica.

Licencia y condiciones de uso: El dataset se distribuye bajo licencia de uso abierto para fines de investigación y educación. En este proyecto, se utiliza exclusivamente con propósitos académicos y de prototipado, sin fines comerciales.

Calidad del dataset: Las imágenes presentan buena resolución y diversidad de ángulos, aunque con cierta variabilidad en fondos y condiciones de iluminación. Esta característica lo hace adecuado para probar la generalización del modelo más allá del dataset principal (pañales), incrementando su robustez frente a variaciones en objetos.



Figura 4: Jarra / FUENTE: KAGGLE CALTECH 101

2.9 DESCRIPCIÓN DEL DATASET 3 – BARRILES

Descripción técnica: El dataset contiene imágenes de barriles incluidas dentro del mismo conjunto Caltech-101, con resolución promedio de 300×300 píxeles en formato JPG. La estructura está segmentada por carpetas de clase, lo que permite su uso en tareas de clasificación supervisada y análisis de formas volumétricas.

Procedencia de los datos: Las imágenes fueron obtenidas del repositorio público de Kaggle: Caltech-101 Dataset.

Licencia y condiciones de uso: El dataset cuenta con licencia de acceso libre para investigación. En este trabajo se aplica únicamente para propósitos académicos, reforzando el prototipo de visión artificial en tareas de estimación de medidas y clasificación de objetos volumétricos.

Calidad del dataset: Las imágenes son de buena calidad y diversidad, aunque presentan heterogeneidad en el fondo, lo que introduce un grado de ruido visual.



Figura 5: Barril / FUENTE: KAGGLE CALTECH 101

2.10 TABLA COMPARATIVA DE DATASET

Dataset	Procedencia	Tamaño / Formato	Licencia	Calidad	Rol en el proyecto
Dataset 1 – Pilas de pañales	EVA ENGINEERING, código IN34-EVA1200 REV 01	100 imágenes, JPG, $\approx 640 \times 640$ px	Licencia otorgada por EVA ENGINEERING, uso académico	Alta consistencia en iluminación y etiquetas confiables	Dataset principal para entrenamiento y validación en entorno controlado
Dataset 2 – Jarras	Kaggle (Caltech-101)	$\approx 300 \times 300$ px, JPG	Licencia abierta de investigación y educación	Buena resolución, fondos variables	Dataset complementario para estimación de dimensiones y clasificación de formas regulares
Dataset 3 – Barriles	Kaggle (Caltech-101)	$\approx 300 \times 300$ px, JPG	Licencia abierta de investigación y educación	Imágenes diversas con heterogeneidad en fondo	Dataset complementario para validar robustez en objetos volumétricos

Tabla 2: Comparativa de datasets Proyecto Integrado Visión Artificial / FUENTE: Generado ChatGPT

2.11 CODIGO FUENTE EJEMPLO

Se presenta un estudio sobre la aplicación de una arquitectura de red neuronal profunda, ResNet18, para la clasificación de imágenes en seis categorías seleccionadas del dataset Caltech101: "camera", "brain", "Faces", "watch", "ketch", "dollar_bill". El enfoque incluye fine-tuning, data augmentation y evaluación técnica rigurosa, con el objetivo de medir la capacidad de generalización y la adaptabilidad del modelo en un escenario controlado pero representativo.

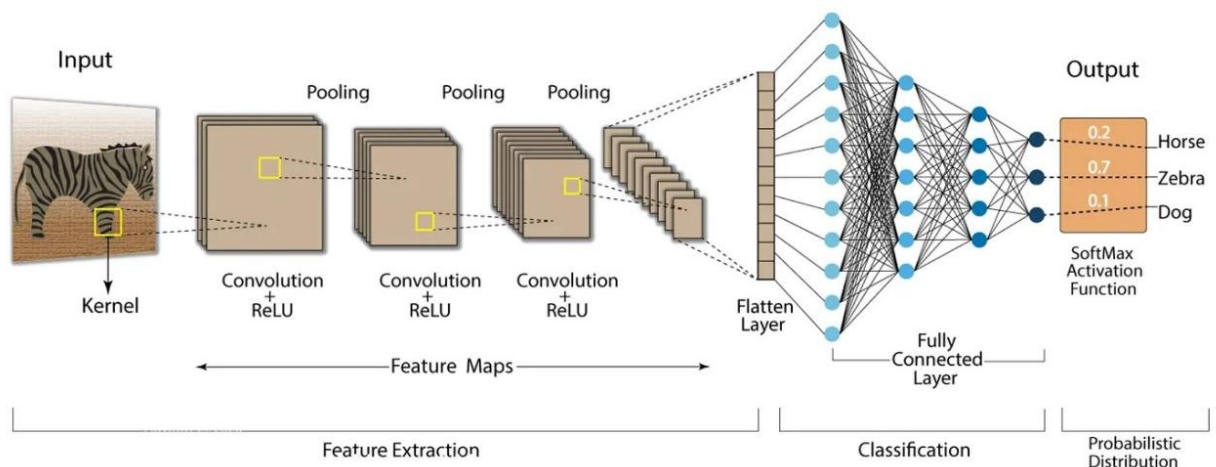


Figura 6: Redes CNN / FUENTE: <https://cs231n.github.io/convolutional-networks/>

<https://github.com/DAVOALEJO1987/Redes-Neuronales-Convolucionales.git>

3. DEFINICIÓN DE MÉTRICAS DE ÉXITO

3.1 MÉTRICAS TÉCNICAS

Categoría	Métrica	Definición	Valor objetivo (criterio de éxito)	Fórmula / Método de cálculo
Principal	F1-Score	Equilibrio entre precisión y recall en clasificación binaria (correcto/incorrecto)	≥ 0.85	$2 \times (\text{Precisión} \times \text{Recall}) / (\text{Precisión} + \text{Recall})$
	mAP (mean Average Precision)	Precisión promedio por clase; mide desempeño global del modelo de detección/clasificación	≥ 0.70	Cálculo con métricas COCO (área bajo curva PR por clase)
	IoU (Intersection over Union)	Superposición entre predicción y anotación real (bounding box)	≥ 0.50	Área de intersección / Área de unión
Secundaria	Precisión (Precision)	% de predicciones correctas entre todas las predicciones positivas	≥ 0.85	$VP / (VP + FP)$
	Recall (Sensibilidad)	% de positivos correctamente detectados	≥ 0.80	$VP / (VP + FN)$
	False Positive Rate (FPR)	% de detecciones incorrectas	$\leq 5\%$	$FP / (FP + VN)$
Eficiencia	FPS (Frames por segundo)	Imágenes procesadas por segundo (tiempo real)	≥ 30 FPS	Benchmark en inferencia
	Latencia de inferencia	Tiempo entre captura de imagen y salida de predicción	≤ 2 segundos	Promedio en pruebas de hardware
	Uso de recursos (CPU/GPU)	% de utilización de hardware durante la inferencia	$\leq 80\%$ de carga sostenida	Medición con herramientas de monitoreo (nvidia-smi, top)

Tabla 3: Métrica de éxito / FUENTE: Generado ChatGPT

3.2 MÉTRICAS DE IMPACTO

Es importante mencionar que, en esta fase inicial, no se contempla la implementación ni validación del sistema en una línea de producción industrial real. El prototipo será probado únicamente en un entorno controlado, utilizando imágenes previamente capturadas y sometidas a procesos de preprocesamiento. Por tal razón, las métricas de impacto definidas en esta etapa deben considerarse de carácter teórico o supuestas, ya que su validación práctica dependerá de una futura fase de escalamiento en planta, donde se podrá medir de manera objetiva la reducción de intervención humana, la eficiencia operativa y la satisfacción de los usuarios finales.

Categoría	Métrica	Definición	Valor objetivo (criterio de éxito)	Método de medición
KPIs (Desempeño del negocio / proceso)	Reducción de intervención humana	% de disminución en la verificación manual de apilamiento	≥ 70% en etapa futura de escalamiento	Comparación de tiempo-hombre antes vs después
	Eficiencia operativa	% de incremento en el flujo de inspección (paquetes/minuto)	+20% respecto al proceso manual	Registro de línea de producción
	Cumplimiento de calidad	% de apilamientos correctamente inspeccionados según estándar	≥ 95%	Auditorías internas / control de calidad
Uso / Adopción	Tasa de uso del sistema	% de tiempo en que el sistema es usado vs tiempo total de línea	≥ 80%	Monitoreo en planta (logs de uso)
	Frecuencia de actualizaciones	Nº de iteraciones o mejoras integradas al sistema	≥ 2 actualizaciones por semestre	Registro en repositorio / bitácora Jira
	Escalabilidad a nuevas líneas	Nº de líneas/planta donde se replica el sistema	≥ 1 piloto escalado	Informe de adopción empresarial
Indicadores de satisfacción de usuario	Satisfacción del operario	Percepción del trabajador respecto al sistema (ergonomía, facilidad)	≥ 4/5 en encuestas	Encuesta de usabilidad SUS (System Usability Scale)
	Satisfacción de supervisión / calidad	Grado de confianza de supervisores en el sistema	≥ 85% aprobación	Encuestas / entrevistas semiestructuradas
	Percepción de reducción de riesgo	Opinión de usuarios sobre disminución de riesgos ergonómicos y asépticos	≥ 80% de respuestas positivas	Encuestas de seguridad y salud ocupacional

Tabla 4: Métrica de impacto / FUENTE: Generado ChatGPT

3.3 UMBRALES DE ÉXITO

La tabla de umbrales de éxito establece una referencia comparativa entre los valores mínimos aceptables para el presente prototipo y los benchmarks industriales observados en sistemas de visión artificial aplicados en sectores como alimentos y farmacéuticos. Es fundamental aclarar que, dado que en esta fase inicial no se contempla la implementación en planta real, los valores alcanzados en el PoC corresponden a un entorno controlado con un dataset reducido de 100 imágenes. Por esta razón, los umbrales definidos deben entenderse como criterios académicos y experimentales, útiles para validar la factibilidad técnica del modelo en laboratorio, pero aún alejados de los estándares exigidos en producción industrial. La convergencia hacia los valores de benchmark industrial —como F1-Score ≥ 0.90 , mAP ≥ 0.80 o latencia ≤ 500 ms— se plantea como parte de un escalonamiento futuro, en el que será posible medir y ajustar el sistema bajo condiciones operativas reales, considerando factores adicionales como robustez frente a variabilidad, estabilidad en hardware y validación en línea de producción.

Métrica	Valor mínimo aceptable (PoC)	Benchmark industrial (referencia)	Fuente / Contexto
F1-Score	≥ 0.80	0.90 – 0.95 en sistemas de inspección de empaque alimenticio/farmacéutico	[6],[10]
Precisión (Precision)	≥ 0.80	0.90 – 0.95 en control de defectos industriales	[6]
Recall (Sensibilidad)	≥ 0.75	0.85 – 0.95 en detección de defectos	[3],[4]
mAP (mean Average Precision)	≥ 0.70	0.80 – 0.90 en benchmarks COCO para visión industrial	[4],[22]
IoU (Intersection over Union)	≥ 0.50	0.60 – 0.75 en detección precisa de objetos	[4],[10]
False Positive Rate (FPR)	$\leq 10\%$	$\leq 5\%$ en sistemas productivos certificados	[6]
FPS (Frames por segundo)	≥ 15 FPS (prototipo controlado)	≥ 30 FPS en producción industrial en tiempo real	[10]
Latencia de inferencia	≤ 2 segundos	≤ 500 ms en aplicaciones en línea de empaque	[9]
Disponibilidad del sistema (uptime)	$\geq 80\%$ (entorno de pruebas)	$\geq 95\%$ en despliegue industrial	Benchmarks industriales generales

Tabla 5: Umbral del Éxito / FUENTE: Generado ChatGPT

4. ANÁLISIS DE STAKEHOLDERS

4.1 PRIMARIOS Maestranes

- ✓ **Rol e influencia:** Ejecutores directos del prototipo; alta influencia técnica en resultados.
- ✓ **Necesidades/expectativas:** Acceso a dataset, hardware, bibliografía y guía metodológica. Reconocimiento académico y validación de avances.
- ✓ **Barreras:** Limitación de tiempo (6 semanas), curva de aprendizaje técnica, dataset reducido.
- ✓ **Estrategia de involucramiento:** Acompañamiento constante por parte de la tutora, reuniones semanales de revisión, uso de Jira para trazabilidad.

Tutora académica (Product Owner)

- ✓ **Rol e influencia:** Define visión, valida entregables y asegura alineación académica; influencia alta en el cumplimiento metodológico.
- ✓ **Necesidades/expectativas:** Avances claros y documentados, métricas medibles, cumplimiento de cronograma.
- ✓ **Barreras:** Posible desfase entre tiempos académicos y técnicos.
- ✓ **Estrategia de involucramiento:** Reportes quincenales, entregas parciales, revisión de documentación bajo formato IEEE.

4.2 SECUNDARIOS Operarios de planta (usuarios finales en un escenario futuro)

- ✓ **Rol e influencia:** Usuarios de la solución en planta; influencia moderada en adopción práctica.
- ✓ **Necesidades/expectativas:** Que el sistema reduzca la carga ergonómica y elimine tareas repetitivas. Facilidad de uso e integración con su rutina.
- ✓ **Barreras:** Resistencia al cambio, miedo a la sustitución laboral.
- ✓ **Estrategia de involucramiento:** Comunicación clara de que el sistema complementa su labor, capacitaciones en fases futuras de escalamiento.

Supervisión de calidad

- ✓ **Rol e influencia:** Validadores de la pertinencia del sistema en control de calidad; influencia moderada.
- ✓ **Necesidades/expectativas:** Garantía de inocuidad, confiabilidad de métricas, trazabilidad en inspección.
- ✓ **Barreras:** Desconfianza en métricas teóricas (PoC no aplicado en planta).
- ✓ **Estrategia de involucramiento:** Presentar resultados con métricas objetivas (F1, mAP, IoU) y escenarios de escalamiento controlado.

4.3 SPONSORS EVA ENGINEERING (empresa auspiciante)

- ✓ **Rol e influencia:** Sponsor principal; provee hardware, dataset y soporte técnico. Influencia decisiva en recursos y validación de aplicabilidad industrial.
- ✓ **Necesidades/expectativas:** Que el prototipo tenga proyección de escalamiento a planta y represente un aporte innovador al sector.
- ✓ **Barreras:** Limitación de pruebas en entorno real, resultados aún teóricos.
- ✓ **Estrategia de involucramiento:** Informes periódicos de avances, reuniones de retroalimentación, documentación del potencial de escalabilidad industrial.

5. DOCUMENTOS DE ALCANCE DEL PROYECTO

5.1 OBJETIVO GENERAL:

En un plazo de **6 semanas**, desarrollar un prototipo funcional de **visión artificial basado en CNN** que, mediante una cámara industrial y técnicas de preprocesamiento (normalización, filtrado, aumento de datos y segmentación), verifique automáticamente el apilamiento de pañales antes del empaque secundario. El sistema deberá alcanzar un **mAP ≥ 0.7** , un **IoU > 0.5** y una **velocidad de procesamiento mayor a 30 FPS**, reduciendo en un **70% la intervención manual** y mitigando riesgos ergonómicos y asépticos, con el fin de optimizar la calidad y eficiencia operativa.

Criterio **SMART**:

- ✓ **S (Específico)**: Se enfoca en la inspección automática del apilamiento de pañales con CNN y cámara industrial.
- ✓ **M (Medible)**: Incluye métricas concretas (mAP ≥ 0.7 , un IoU > 0.5 y una velocidad de procesamiento mayor a 30 FPS, reduciendo en un 70% la intervención manual).
- ✓ **A (Alcanzable)**: Se plantea con recursos accesibles (cámara industrial, dataset propio, librerías de ML).
- ✓ **R (Relevante)**: Reduce errores humanos, riesgos ergonómicos y contaminación, alineado a la mejora de calidad y eficiencia.
- ✓ **T (Temporal)**: Plazo definido de 6 meses.

5.2 OBJETIVOS ESPECÍFICOS:

Buscar o construir y etiquetar un dataset de al menos 100 imágenes de apilamientos correctos e incorrectos de pañales, aplicando técnicas de normalización, filtrado y aumento de datos, garantizando un balance adecuado de clases y una consistencia de etiquetado superior al 95%.

Diseñar, entrenar y validar un modelo de red neuronal convolucional (CNN) para la clasificación automática del apilamiento de pañales, alcanzando un mAP ≥ 0.7 , un IoU > 0.5 , una precisión mínima del 90% y un F1-score ≥ 0.89 en el dataset de validación.

Implementar el prototipo del sistema en una línea piloto virtual de producción, integrando una cámara industrial y un módulo de procesamiento en tiempo real, asegurando una velocidad de procesamiento superior a 30 FPS y una latencia máxima de 2 segundos por verificación.

5.3 ALCANCE INCLUIDO:

El proyecto consiste en el desarrollo de un **prototipo de visión artificial basado en aprendizaje supervisado** para la verificación automática del apilamiento de pañales antes del empaque secundario. El alcance abarca:

1. **Captura y selección de datos**: Recolección y etiquetado de un conjunto inicial de **100 imágenes** de apilamientos correctos e incorrectos, tomadas con una cámara industrial instalada en la línea de producción.
2. **Preprocesamiento de imágenes**: Aplicación de técnicas de **normalización, filtrado y aumento de datos (data augmentation)** con el fin de ampliar la variabilidad del dataset y compensar la cantidad limitada de imágenes.
3. **Entrenamiento de modelo supervisado**: Implementación de una **red neuronal convolucional (CNN)** entrenada con el dataset ampliado artificialmente, orientada a clasificar apilamientos correctos e incorrectos.
4. **Validación preliminar**: Evaluación del prototipo mediante métricas de desempeño en visión por computadora como **precisión, recall y F1-score**, con el objetivo de establecer una línea base de resultados.
5. **Prueba piloto en entorno controlado**: Integración del sistema a nivel experimental para validar su funcionamiento en tiempo real con imágenes de la línea de producción, generando evidencia sobre la factibilidad de escalar el modelo a datasets más amplios en fases posteriores.

5.4 ALCANCE EXCLUIDO:

Implementación en planta real: En esta fase inicial no se realizará la instalación ni la validación del sistema en una línea de producción industrial real. El prototipo se probará únicamente en un entorno controlado con imágenes capturadas y preprocesadas.

Medición de impacto operativo: No se evaluará el desempeño relacionado con la reducción del 70% de la intervención manual, ni la disminución de riesgos ergonómicos o asépticos en los operarios. Estos aspectos corresponden a una fase de escalonamiento futuro cuando el sistema sea entrenado con un dataset más amplio y validado en planta.

Integración total con infraestructura de producción: El proyecto no contempla en esta etapa la conexión del sistema con la línea de control de calidad ni con el sistema SCADA/PLC de la planta. Esta integración será considerada en fases posteriores del desarrollo.

5.5 CRITERIOS DE ACEPTACIÓN:

Los criterios, condiciones estándares y procedimientos se describen en la siguiente tabla:

Criterio	Condiciones específicas	Estándares de calidad mínimos	Procedimientos de validación
Dataset de imágenes	Captura y etiquetado de al menos 100 imágenes de apilamientos correctos e incorrectos con cámara industrial.	Dataset balanceado con $\geq 90\%$ de consistencia en las etiquetas.	Revisión cruzada de las etiquetas por dos personas distintas y muestreo aleatorio para validación de calidad.
Preprocesamiento de datos	Aplicación de normalización, filtrado y aumento de datos (rotación, brillo, escalado).	Dataset aumentado con al menos 500 imágenes artificiales adicionales para robustecer el modelo.	Inspección visual de las imágenes generadas y verificación de variabilidad introducida.
Modelo CNN	Entrenamiento con dataset preprocesado y pruebas en entorno controlado.	Alcanzar un mínimo de Precisión $\geq 85\%$, Recall $\geq 80\%$ y F1-score ≥ 0.82 .	Evaluación con conjunto de validación independiente (20% de las imágenes).
Resultados preliminares	Clasificación de apilamiento correcto/incorrecto en imágenes controladas.	El modelo debe identificar correctamente al menos 8 de cada 10 casos en validación.	Generación de reporte con métricas: matriz de confusión, precisión, recall y F1-score.
Prueba piloto en entorno controlado	Ejecución del modelo con cámara en pruebas offline o semirrealistas (no en planta).	Procesamiento en tiempo ≤ 2 segundos por imagen.	Registro de tiempos de inferencia y reporte técnico de desempeño.

Tabla 6: Criterios de aceptación / FUENTE: Generado ChatGPT

6. CRONOGRAMA CON METODOLOGÍA ÁGIL

Una vez que el proyecto de visión artificial sea validado y aprobado en su fase inicial, el seguimiento, control de avances y gestión del cronograma definitivo se llevará a cabo mediante la plataforma Jira Software, bajo la metodología ágil Scrum. En esta herramienta se configurarán los Sprints definidos, con sus respectivas User Stories, tareas técnicas, criterios de aceptación y Definition of Done, lo que permitirá una trazabilidad clara de cada entregable.

El uso de Jira facilitará:

- ✓ La **visualización del progreso** en tableros Kanban y diagramas de burndown.
- ✓ La **gestión de incidencias y riesgos** de manera centralizada.
- ✓ La **transparencia** en la comunicación entre la tutora (Product Owner), el maestrante (Scrum Team) y la empresa auspiciante (Stakeholder).
- ✓ La **presentación del cronograma definitivo**, actualizado de acuerdo con la ejecución real de los Sprints y la retroalimentación recibida en cada iteración.

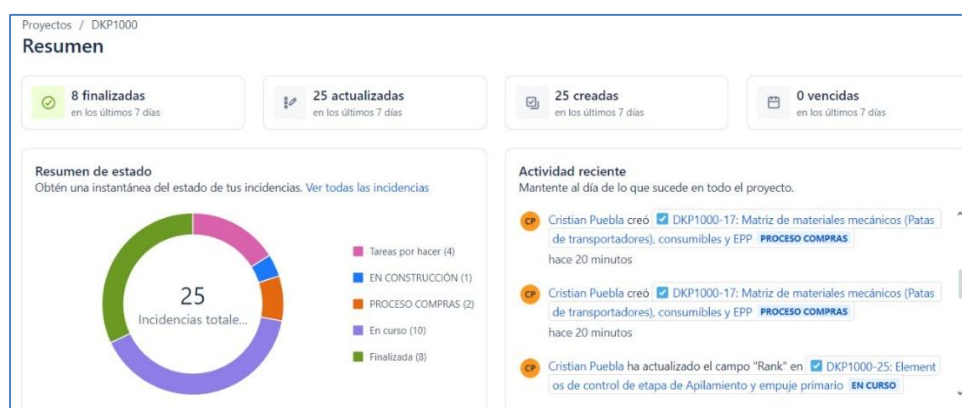


Figura 7: Resumen tablero Kanban / FUENTE: JIRA

De esta forma, Jira se convertirá en la herramienta oficial para el control del proyecto, garantizando la alineación entre los objetivos académicos y la aplicabilidad industrial.

6.1 ROLES SCRUM DEL PROYECTO

Rol Scrum	Participante	Enfoque principal
Product Owner	Tutora	Define visión, prioriza backlog y valida entregables
Scrum Team	Maestrante (Alejandro)	Desarrolla, entrena y valida el prototipo de IA
Stakeholder / Usuario Final	Empresa auspiciante	Aporta contexto industrial y valida utilidad práctica

Tabla 7: Roles de integrantes SCRUM método / FUENTE: Generado ChatGPT

6.2 DIAGRAMA GANTT




Figura 8: Diagrama Gantt / FUENTE: Generado ChatGPT

6.3 SPRINT 1 – INVESTIGACIÓN Y DISEÑO

Semana 1 – 1,5

Goal: Definir el marco técnico y preparar el entorno para el desarrollo del prototipo.

User Stories:

- ✓ Como investigador, quiero analizar los requisitos del sistema para definir la arquitectura técnica.
- ✓ Como desarrollador, necesito preparar el entorno de desarrollo (Python, librerías, frameworks de visión por computadora).
- ✓ Como ingeniero de IA, quiero recolectar y etiquetar 100 imágenes para construir el dataset inicial.

Definition of Done:

- ✓ Documento de arquitectura aprobado.
- ✓ Entorno de desarrollo operativo.
- ✓ Dataset inicial de 100 imágenes etiquetadas y almacenadas.

Riesgos Identificados: Dataset insuficiente para entrenar un modelo robusto.

Plan de Mitigación: Aplicar data augmentation (rotaciones, escalado, variaciones de brillo) para aumentar la variabilidad del dataset.

6.4 SPRINT 2 – DESARROLLO CORE

Semana 2 – 3

Goal: Implementar el modelo base (CNN) y asegurar su integración con el dataset.

User Stories:

- ✓ Como científico de datos, quiero entrenar una CNN inicial para clasificar apilamientos correctos e incorrectos.
- ✓ Como desarrollador, quiero integrar el modelo con el dataset aumentado.
- ✓ Como tester, necesito ejecutar pruebas unitarias del preprocesamiento y pruebas de integración del modelo.

Definition of Done:

- ✓ Modelo CNN entrenado con dataset preprocesado.
- ✓ Pruebas unitarias e integración documentadas.
- ✓ Resultados preliminares con métricas iniciales (precisión, recall, F1-score).

Riesgos Identificados: Bajo rendimiento del modelo (precisión < 70%).

Plan de Mitigación: Ajustar arquitectura de la CNN (capas, filtros) y aumentar la cantidad de imágenes artificiales generadas.

6.5 SPRINT 3 – OPTIMIZACIÓN Y VALIDACIÓN

Semana 4 – 5

Goal: Optimizar el modelo y validar su desempeño con métricas claras.

User Stories:

- ✓ Como ingeniero de IA, quiero realizar tuning de hiperparámetros para mejorar el rendimiento.
- ✓ Como analista de calidad, quiero validar el modelo con métricas de visión por computadora (mAP, IoU, F1-score).
- ✓ Como usuario final, necesito una interfaz simple que muestre la clasificación del apilamiento.

Definition of Done:

- ✓ CNN optimizada con precisión $\geq 85\%$, recall $\geq 80\%$, F1 ≥ 0.82 .
- ✓ Reporte de métricas generado y validado.
- ✓ Prototipo con interfaz básica operativa.

Riesgos Identificados: Overfitting por bajo número de imágenes.

Plan de Mitigación: Aplicar validación cruzada y regularización (dropout, early stopping).

6.6 SPRINT 4 – FINALIZACIÓN Y DOCUMENTACIÓN

Semana 6

Goal: Completar pruebas, documentar y preparar la presentación final.

User Stories:

- ✓ Como ingeniero de QA, necesito ejecutar pruebas integrales del prototipo.
- ✓ Como docente/cliente, quiero recibir documentación técnica y de usuario.
- ✓ Como equipo de proyecto, quiero preparar la presentación final para mostrar resultados y aprendizajes.

Definition of Done:

- ✓ Prototipo probado en entorno controlado.
- ✓ Documentación técnica (arquitectura, dataset, métricas) y manual de usuario entregados.
- ✓ Presentación final lista.

Riesgos Identificados: Fallas de integración en la fase final.

Plan de Mitigación: Pruebas incrementales desde la semana 5 para detectar errores antes del cierre.

7. PLAN DE RECURSOS

En el marco del plan de recursos, es importante destacar que esta aplicación de visión artificial tiene un alto interés industrial, dado que responde a necesidades críticas de inspección y control de calidad en líneas de producción. En esta fase inicial, el desarrollo del prototipo será auspiciado por la empresa EVA ENGINEERING, que aportará su experiencia en automatización y robótica industrial, así como el soporte técnico y logístico necesario para la experimentación en entorno controlado. Este auspicio no solo garantiza la disponibilidad de recursos tecnológicos —equipos de cómputo, cámaras industriales y herramientas de software—, sino que además asegura la pertinencia práctica del proyecto al alinearse con los requerimientos reales de la industria de producción masiva, fortaleciendo la conexión entre la investigación académica y la aplicación empresarial.

7.1 RECURSOS HUMANOS

Categoría	Detalle	Cantidad
Recursos Humanos	Maestranes (investigación, desarrollo, validación – 6 semanas)	2
	Tutora académica (supervisión, revisión de avances)	1
	Soporte técnico EVA ENGINEERING (instalación, pruebas hardware)	1

Tabla 8: Recursos humano / FUENTE: Generado ChatGPT

En el marco de la metodología Scrum, los roles del proyecto se distribuyen estratégicamente para garantizar un flujo de trabajo ágil y enfocado en resultados. La tutora, en su rol de *Product Owner*, es responsable de definir la visión del producto, priorizar el backlog y validar los entregables, asegurando la alineación académica y metodológica. El maestrante, como parte del *Scrum Team*, asume la ejecución técnica del proyecto, desarrollando, entrenando y validando el prototipo de visión artificial con base en los requerimientos definidos. Finalmente, la empresa auspiciante (EVA ENGINEERING) participa como *Stakeholder/Usuario Final*, aportando el contexto industrial, verificando la pertinencia práctica y asegurando que la solución propuesta se oriente a resolver necesidades reales del sector productivo. Esta distribución de roles promueve una interacción continua entre academia e industria, fortaleciendo tanto la rigurosidad científica como la aplicabilidad del prototipo en escenarios industriales.

7.2 RECURSOS TÉCNICOS

Categoría	Elemento	Cantidad / Detalle
Hardware	Raspberry Pi 5, 8GB RAM, 128GB almacenamiento	1
Hardware	Cámara SVPRO 4K 60fps, lente 2.8-12mm	1
Hardware	Cables Ethernet y material instalación	Varios
Software	Python	Licencia disponible

Tabla 9: Recursos / FUENTE: Generado ChatGPT

Hardware:

- ✓ Tarjeta de desarrollo con almacenamiento incluido y conexión para cámara de video
- ✓ Cámara de video industrial con salida digital USB
- ✓ Cables de conexión Ethernet y material de instalación

Software y licencias:

- ✓ Python (disponible)
- ✓ Visual Studio (disponible)
- ✓ TIA Portal V19 (disponible)

7.3 RECURSOS FINANCIEROS

La empresa EVA ENGINEERING auspicia este proyecto mediante la provisión del hardware requerido, el soporte técnico especializado para la instalación y pruebas en entorno controlado, así como la colaboración en la construcción del dataset de imágenes necesarias para el entrenamiento y validación del modelo. Este apoyo garantiza que el prototipo cuente con recursos tecnológicos y de conocimiento alineados con estándares industriales, fortaleciendo la pertinencia práctica del trabajo desarrollado en el marco académico.

Categoría	Detalle	Cantidad	Costo unitario (USD)	Subtotal (USD)
Recursos Humanos	Maestranteros (investigación, desarrollo, validación – 6 semanas)	2	1,500	3,000
	Tutora académica (supervisión, revisión de avances)	1	1,000	1,000
	Soporte técnico EVA ENGINEERING (instalación, pruebas hardware)	1	1,200	1,200
Subtotal Recursos Humanos				5,200
Hardware	Raspberry Pi 5, 8GB RAM, 128GB almacenamiento	1	120	120
	Cámara SVPRO 4K 60fps, lente 2.8–12mm	1	150	150
	Cables Ethernet y material de instalación	Varios	80	80
Subtotal Hardware				350
Software	Python (licencia libre)	-	0	0
	Librerías IA (TensorFlow, PyTorch, OpenCV, Scikit-learn)	-	0	0
Subtotal Software				0
Contingencia (15%)	Cobertura de imprevistos en hardware, reposición, soporte extra	-	-	832.5
TOTAL PROYECTO				6,382.50 USD

Tabla 10: Análisis económico / FUENTE: Generado ChatGPT

8. HITOS Y ENTREGABLES

La siguiente tabla muestra los 6 hitos de entregables medibles, distribuidos semana a semana, alineados la sección 6, cronograma de trabajo con metodología ágil.

Semana / Fase	Hito	Entregable	Tipo de archivo	Criterios de medición
Semana 1 / Exploración de Datos	Planificación y Cronograma en Jira	Tablero Jira con backlog y sprints + EDA preliminar	Captura Jira (PDF/PNG), Reporte EDA (Word/PDF)	100% tareas cargadas en Jira; entrega de reporte de calidad de datos
Semana 2 / Exploración de Datos	Dataset inicial recolectado y etiquetado	100 imágenes etiquetadas + Data Quality Report	Carpeta imágenes, CSV/JSON de etiquetas, reporte PDF	Dataset estructurado (80/20 split); ≥95% etiquetas correctas
Semana 3 / Prototipo/MVP	Implementación del modelo base en Python	Script CNN inicial + Modelo Base Funcional	Script Python (*.py / *.ipynb)	Ejecución sin errores; precisión ≥70% en validación
Semana 4 / Desarrollo	Validación de métricas del modelo	Reporte con métricas + API inicial	Documento técnico (Word/PDF), gráficas PNG, notebook con API	mAP ≥0.7; IoU ≥0.5; F1 ≥0.80 documentados
Semana 5 / Testing + Deploy Piloto	Prueba con hardware en entorno controlado	Validación en cámara + Producción limitada	Vídeo/Imagen (MP4/PNG), Reporte Testing Plan	Latencia ≤2 s; FPS ≥30; evidencia en hardware
Semana 6 / Deploy Completo	Entrega final del prototipo y documentación	Prototipo optimizado + Documentación técnica + Presentación final	Script (.py/.ipynb), Documentación (PDF/Word), Presentación (PPTX)	Documentación completa; manual validado; demostración del prototipo con monitoreo básico

Tabla 11: Hitos y entregables / FUENTE: Generado ChatGPT